AN END-TO-END CRNN AND CTC APPROACH FOR OFFLINE HANDWRITTEN CHINESE TEXT RECOGNITION

Stefanus Eko Prasetyo[1], Jeffrey[2,] Haeruddin[3]
Program Studi Teknik Informasi, Fakultas Ilmu Komputer, Universitas Internasional Batam
Baloi-Sei Ladi, Jl. Gajah Mada, Tiban Indah, Kec. Sekupang, Kota Batam,
Kepulauan Riau, telp. (0778) 7437111
e-mail: [1]Stefanus@uib.ac.id, [2]2232067.jeffrey@uib.edu, [3]Haeruddin@uib.ac.id

Abstract

Offline handwritten Chinese text recognition remains a challenging problem due to the large number of character classes, complex character structures, and high variability in writing styles. This paper proposes an end-to-end offline handwritten Chinese text recognition system based on a CNN–BiLSTM–CTC architecture. A convolutional neural network (CNN) is used to extract spatial features from handwritten text images, while a bidirectional long short-term memory (BiLSTM) network captures contextual dependencies between characters in both forward and backward directions. The Connectionist Temporal Classification (CTC) framework is applied to enable segmentation-free training and decoding of character sequences directly from input images. Experiments conducted on the CASIA-HWDB 2.2 offline handwritten Chinese text dataset demonstrate that the proposed approach achieves a Character Error Rate (CER) of 16,85%, corresponding to an accuracy of 83,15%, confirming the effectiveness of the CNN–BiLSTM–CTC framework for offline handwritten Chinese text recognition.

Keywords: *Offline Handwritten Chinese Text Recognition, Convolutional Neural Network (CNN), Bi-directional Long Short-term Memory (BiLSTM), Connectionist Temporal Classification (CTC), Character Error Rate (CER)*

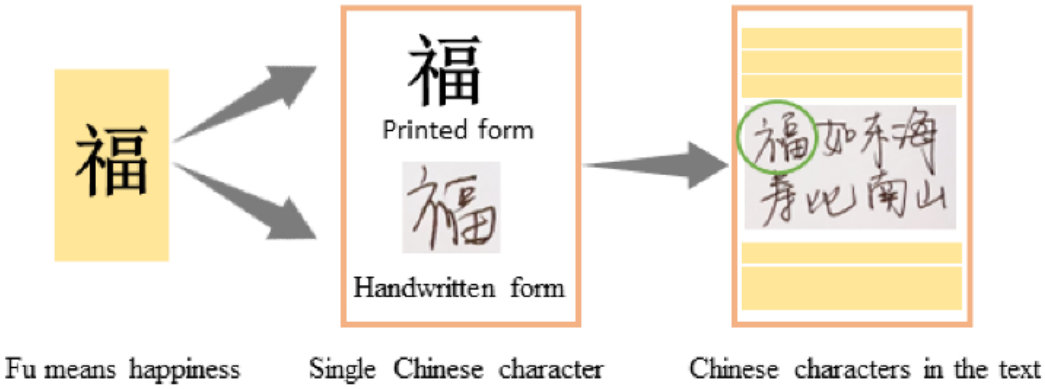
PENDAHULUAN

Salah satu terobosan besar *Human-Computer Interaction* (HCI) adalah penerapan *machine learning*, yang memungkinkan komputer memahami input manusia dalam bentuk yang lebih alami, seperti suara, gerakan, maupun tulisan tangan. Pengenalan teks merupakan bagian penting dari *machine learning* dan *pattern recognition*. Perkembangan teknik-teknik ini telah menghasilkan kemajuan signifikan dalam kemampuan komputer untuk memproses serta menginterpretasikan data kompleks yang dihasilkan manusia, termasuk teks tulisan tangan dan pola Gerakan (Geetha et al., 2021), (Zhuang et al., 2021), (Liu et al., 2020). Dengan meningkatnya penggunaan teknologi *deep learning*, pengenalan teks multibahasa—baik pengenalan teks cetak, tulisan tangan, maupun teks pada gambar—menjadi bidang penelitian yang aktif dan terus mengalami terobosan baru (Mamuriyah & Jacky, 2021), (Mamuriyah & Sumantri, 2022).

Meskipun demikian, pada bidang pengenalan tulisan tangan khususnya pada bidang *Handwritten Chinese Text Recognition* (HCTR) masih banyak menghadapi tantangan-tantangan berupa jumlah kelas karakter dengan jumlah yang sangat besar, variasi gaya tulisan yang tinggi, tantangan dalam melakukan segmentasi karakter serta penggunaan domain bahasa yang tidak terikat (Liu et al., 2020). Terlepas itu, masih banyak penelitian-penelitian yang mendapatkan hasil akurasi tinggi. Sebagian besar penelitian terkini menggunakan arsitektur *hybrid* CNN dan RNN/LSTM untuk pengenalan teks (Alkendi et al., 2024). Namun, untuk mengurangi kompleksitas *model* dan meningkatkan efisiensi pelatihan, mulai berkembang pendekatan tanpa rekuren yang memanfaatkan jaringan konvolusional murni dengan paralelisme yang lebih baik.

Secara umum *Handwritten Recognition* memiliki dua pendekatan yang terdiri dari *Online Handwritten Recognition* yang mengambil pergerakan pena melalui *device* seperti *tablet* atau *handphone* sebagai *input* dan *Offline Handwritten Recognition* (Vinh et al., 2020) yang hanya menggunakan input dari hasil scan images/citra. Dalam hal ini, artikel ini akan membahas dan mengimplementasikan secara spesifik pada *Offline Handwritten Chinese Text Recognition* yang dapat dilihat pada gambar 1.

P-ISSN: 2622-6901
E-ISSN: 2622-6375



Gambar 1. Perbandingan Tulisan karakter Hanzi cetak dan tulisan tangan
Sumber: Shen L et al., 2023

Secara khusus, terdapat beberapa faktor utama yang menyebabkan pengenalan tulisan tangan Mandarin secara *offline* menjadi sulit (Shen et al., 2023):

1. Jumlah karakter Hanzi sangat banyak. Berdasarkan standar *National Standard Simplified Chinese Character Set* (GB2312-80), terdapat 6.763 karakter tingkat pertama dan kedua yang umum digunakan. Setiap karakter merupakan kelas yang berbeda sehingga jumlah kategori pada tugas pengenalan jauh lebih besar dibandingkan bahasa seperti Inggris yang hanya memiliki sekitar dua puluh enam huruf. Hal ini membuat kompleksitas algoritma pengenalan karakter meningkat secara signifikan.
2. Karakter Hanzi memiliki struktur yang kompleks, seperti struktur atas–bawah, kiri–kanan, semi-tertutup, maupun gabungan. Karakter tradisional rata-rata memiliki 16 goresan, sedangkan karakter sederhana memiliki sekitar 11 goresan. Banyaknya goresan dapat menurunkan akurasi pengenalan.
3. Banyak karakter Hanzi yang memiliki bentuk hampir identik, baik dari segi struktur spasial maupun pola goresan—misalnya "己" dan "已", atau "鸟" dan "鸟". Tingkat kemiripan ini menuntut algoritma ekstraksi fitur yang lebih kuat dan sensitif.
4. Setiap individu memiliki gaya tulisan tangan yang berbeda-beda. Bahkan tulisan orang yang sama dapat berubah sesuai kondisi. Selain itu, banyak karakter yang mudah mengalami perubahan bentuk saat ditulis, sehingga semakin menyulitkan proses pengenalan.

Pada implementasi ini, kita akan menggunakan pendekatan sederhana CRNN + CTC. Pendekatan ini akan diuji pada salah satu subset yang sering dipake dalam HCTR yaitu CASIA HWDB. Model *Convolutional Neural Network* (CNN) telah menjadi salah satu model yang sering dipakai dalam bidang pengenalan pola. Hal ini terbukti dengan banyaknya keberhasilan pada HCTR yang menggunakan model tersebut dalam aplikasinya (Zhuang et al., 2021), (Liu et al., 2020), (Z. Wang et al., 2020). Beberapa penelitian sebelumnya, (Zhuang et al., 2021) menggunakan dua *convolutional layer* dan dua *pooling layer*. *Convolutional layer* pertama menggunakan enam kernel untuk menangkap fitur dasar seperti tepi dan goresan sederhana dan layer kedua dua belas kernel untuk mengekstraksi pola yang lebih kompleks dan struktur karakter dengan hasil akurasi yang diperoleh 90.91%. (Chen & Zhao, 2025) mengembangkan dua *convolution layer* berukuran 3×3 dengan 32 dan 64 filter yang masing-masing diikuti oleh *batch normalization*, *max-pooling*, dan *dropout* untuk mengekstraksi fitur goresan dan struktur karakter kaligrafi sebelum dilakukan klasifikasi melalui *fully connected layer*, dan hasil akurasi yang diperoleh 95.6%. RNN sering sekali penerapannya dilakukan bersama dengan CTC (Kang et al., 2021). Pendekatan RNN memungkinkan pemodelan urutan yang fleksibel, sementara penghilangan kebutuhan segmentasi eksplisit secara utama difasilitasi oleh *Connectionist Temporal Classification* (CTC) melalui mekanisme *alignment* otomatis.

Berdasarkan berbagai tantangan pada *Handwritten Chinese Text Recognition* (HCTR), penelitian ini berfokus pada pengembangan sistem pengenalan tulisan tangan Hanzi secara *end-to-end* tanpa memerlukan segmentasi karakter secara eksplisit. Permasalahan utama pada HCTR terletak pada tingginya kompleksitas

struktur karakter Hanzi, jumlah kelas karakter yang sangat besar, serta variasi gaya tulisan tangan antar penulis yang menyebabkan proses segmentasi dan klasifikasi menjadi sulit dilakukan secara konvensional.

Penelitian ini mengusulkan pendekatan *Convolutional Recurrent Neural Network* (CRNN) yang dikombinasikan dengan *Connectionist Temporal Classification* (CTC) untuk mengatasi permasalahan tersebut. CNN digunakan untuk mengekstraksi fitur spasial dari citra tulisan tangan, sedangkan BiLSTM dimanfaatkan untuk mempelajari dependensi kontekstual antar karakter dalam urutan teks. Selanjutnya, CTC memungkinkan proses *alignment* antara *input* citra dan label teks dilakukan secara otomatis tanpa anotasi segmentasi karakter manual.

Kontribusi utama penelitian ini meliputi:

1. Implementasi sistem *end-to-end Offline Handwritten Chinese Text Recognition* berbasis CRNN dan CTC tanpa proses segmentasi karakter eksplisit.
2. Penggunaan pendekatan *variable-width image preprocessing* untuk mempertahankan proporsi karakter Hanzi pada citra tulisan tangan.
3. Evaluasi kuantitatif dan kualitatif terhadap performa model menggunakan Character Error Rate (CER) serta analisis hasil prediksi karakter Hanzi.
4. Penyediaan *baseline* implementasi CRNN-CTC yang ringan dan efisien pada *subset* CASIA-HWDB 2.2 tanpa penggunaan *language model* maupun data sintetis tambahan.

Pendekatan ini menjadi relevan karena sebagian besar penelitian modern HCTR menggunakan arsitektur yang lebih kompleks dan membutuhkan sumber daya komputasi besar. Penelitian ini menunjukkan bahwa pendekatan CRNN + CTC yang lebih sederhana masih mampu memberikan performa yang kompetitif pada pengenalan tulisan tangan Hanzi.

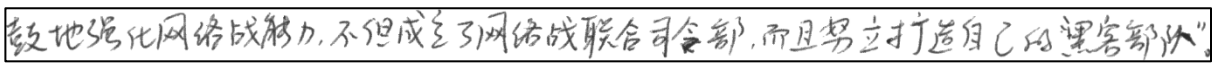
METODE PENELITIAN

1. Dataset

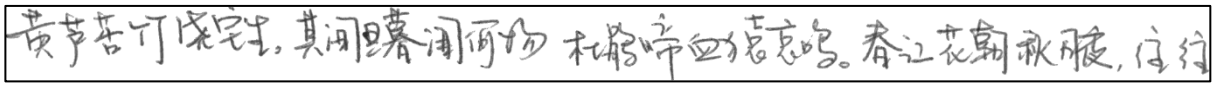
Penelitian ini secara spesifik menggunakan *dataset* dari CASIA-HWDB (Z. Wang et al., 2020), (Li et al., 2020) dengan sub *dataset* CASIA-HWDB 2.2 yang merupakan *dataset offline* untuk HTCR. *Dataset* tersebut dikembangkan oleh *Institute of Automation, Chinese Academy of Sciences* (CASIA). *Dataset* ini berisi kumpulan tulisan tangan teks Hanzi yang telah diproses dalam bentuk gambar *grayscale* dan dilengkapi dengan informasi label karakter berbasis kode GBK. Subset tersebut secara keluruhan melibatkan 300 penulis yang terdapat 14,443 baris teks yang telah disegmentasi dan diberi label. *Dataset* ini memuat 380,993 karakter tulisan tangan yang mewakili 1,331 kelas karakter unik. Setiap *file* halaman dalam HWDB 2.2 disimpan dalam format .dgrl yang membuat gambar halaman, segmentasi baris, *bounding box* karakter, serta label karakter dalam encoding GBK.

Dataset tersebut dipilih karena merupakan salah satu *benchmark* yang paling banyak digunakan pada penelitian *Handwritten Chinese Text Recognition* (HCTR). Dataset ini memiliki variasi gaya tulisan tangan yang tinggi karena dikumpulkan dari ratusan penulis dengan karakteristik tulisan yang berbeda-beda. Variasi tersebut mencakup perbedaan ketebalan stroke, kemiringan tulisan, ukuran karakter, serta perubahan bentuk karakter akibat gaya penulisan individu yang dapat dilihat pada Gambar 2.

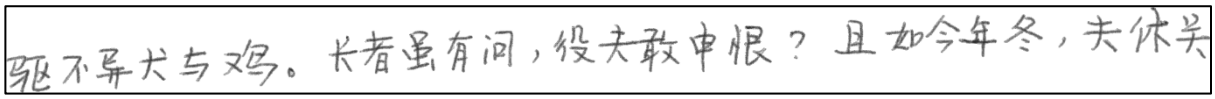
Selain itu, dataset ini juga mencakup ribuan karakter Hanzi dengan kompleksitas struktur yang beragam, mulai dari karakter sederhana hingga karakter dengan jumlah *stroke* tinggi. Keberagaman tersebut menjadikan CASIA-HWDB 2.2 sangat representatif untuk mengevaluasi kemampuan generalisasi model dalam kondisi tulisan tangan nyata.



鼓地强化网络战能力，不但成立了网络战联合司令部，而且努力打造自己的‘‘黑客部队’‘。



黄芦苦竹绕宅生。其间旦暮闻何物杜鹃啼血猿哀鸣。春江花朝秋月夜,往往



驱不异犬与鸡。长者虽有问,役夫敢申恨_且如今年冬,夫休关

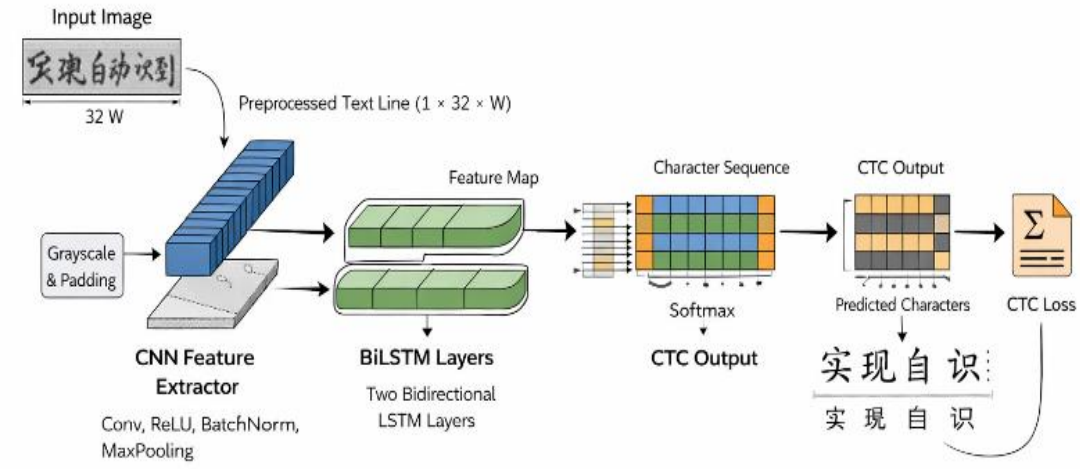
Gambar 2. Sampel pengenalan yang benar
Sumber: Institute of Automation, Chinese Academy of Sciences (CASIA) dataset

Gambar 2 adalah beberapa contoh *dataset* yang telah dikonversi menjadi format *png*. *Dataset* tersebut menggambarkan panjang teks dan lebar citra yang berbeda-beda. Hal ini menjadi sebuah tantangan selama mengolah *dataset* tersebut.

2. Model yang Diusulkan

Penelitian ini mengusulkan model yang sangat sering digunakan dalam bidang pengenalan pola teks yaitu *Convolutional Neural Network* (CNN) (M. Hu et al., 2022), (Xie et al., 2020), (Ayuni et al., 2023), yang dikombinasikan dengan *Recurrent Neural Network* (RNN) dan dioptimalkan menggunakan *Connectionist Temporal Classification* (CTC). Model ini dirancang untuk mengenali urutan karakter secara langsung dari input tulisan tangan tanpa membutuhkan segmentasi eksplisit / manual di tahap pra-proses. Pendekatan ini mengikuti paradigma *segmentation-free* yang umum digunakan pada sistem modern *handwritten text recognition* (HTR). Model ini terdiri dari tiga komponen utama sebagai berikut.

1. *Convolutional Neural Network* (CNN), komponen ini berfungsi untuk mengekstraksi fitur spasial tingkat rendah hingga menengah dari citra tulisan tangan serta mempelajari representasi yang robust terhadap variasi gaya penulisan, seperti ketebalan goresan (*stroke thickness*), bentuk (*shape*), dan gaya tulisan (*style*) (X. Hu & Wu, 2024).
2. *Bidirectional Long Short-Term Memory* (Bi-LSTM), yang bertugas untuk mengubah representasi fitur 2D menjadi urutan fitur 1D dan menangkap dependensi jangka panjang antar karakter dalam satu baris teks (Kass & Vats, 2022), (Gan et al., 2020).
3. CTC *Output Layer*, yang akan melakukan *sequence alignment* tanpa *ground-truth alignment* manual, serta men-*decode* urutan karakter dari *output* model (Gan et al., 2020).



Gambar 3. Diagram arsitektur model

Berdasarkan Gambar 3, alur pemrosesan dimulai dari input citra tulisan tangan Hanzi yang telah melalui tahap *preprocessing*. *Preprossesing* gambar tulisan hasil *dataset* HWDB dimulai dengan konversi *grayscale* untuk mengurangi kompleksitas dan mempertahankan bentuk *stroke* tulisan. Mengingat panjang dan lebar teks yang berbeda-beda, maka diperlukan perhitungan matematika secara baik dalam CNN sehingga dapat diproses oleh CTC nantinya. Dalam hal ini, hasil gambar tersebut mengubah proporsional tinggi dari gambar menjadi 32*px*, dan lebar gambarnya dibiarkan *variable width*. Tujuannya adalah untuk menjaga proporsi tulisan. *Padding* dinamis juga dilakukan ditahap ini karena pada saat *training*, setiap *batch* disamakan lebarnya melalui *padding* sehingga CNN dapat memproses data dalam bentuk tensor seragam. Proses ini akan menyebabkan setiap citra/gambar menjadi tensor berukuran (1 x 32 x W) dengan W fleksibel. Selanjutnya adalah membangun *character vocabulary* dengan cara mengambil seluruh karakter unik dari gabungan: label *train*, label *validation*, label *test*.

Kemudian untuk model arsitektur pada penelitian ini akan menggunakan *Convolutional Feature Extractor* yaitu dengan 4 blok konvolusi: kernel 3x3, aktivasi ReLU dan *MaxPooling* untuk menurunkan resolusi bertahap (Yulianto et al., 2023). *Batch Normalization* diterapkan pada lapisan konvolusi tingkat tinggi untuk meningkatkan stabilitas pelatihan. Tujuan dari CNN adalah untuk menyaring fitur lokal seperti bentuk *stroke*, kurva, titik dan garis, mengurangi dimensi sehingga menghasilkan representasi efisien untuk teks panjang. CNN juga akan menghasilkan *feature map* berukuran (512 x 1 x W') setelah *adaptive height pooling*. Pada model CNN juga ditambahkan *AdaptiveAvgPool2d*((1, *None*)) sehingga tinggi *output* CNN dipaksa menjadi 1. Dengan cara ini, teks 2D diarahkan menjadi urutan sepanjang W' disumbu horizontal (*x-axis*), mirip *time steps* pada model *sequential*.

Output CNN berbentuk (*Batch*, *Channels*, *Height*=1, *Width*) kemudian akan di-*squeeze* menjadi (*Batch*, *Channels*, *Width*) dan di-*transpose* menjadi (Width, Batch, Channels) agar sesuai format *input* LSTM. Penelitian ini menggunakan dua lapisan *Bidirectional* LSTM dengan *hidden size* 256 per arah, total 512 dan 2 *layers*. Lapisan ini memungkinkan model untuk menangkap konteks kiri-kanan tulisan, memahami struktur karakter yang saling berdekatan, mengurangi kesalahan pada bentuk karakter mirip. Lapisan akhir adalah *fully connected layer*. *Output* LSTM diubah menjadi probabilitas setiap karakter pada setiap *time-step*. Karena tidak ada *segmentation label*, CTC dalam penelitian ini dipakai untuk melakukan *alignment* otomatis antara *sequence* panjang dan label pendek (Xie et al., 2020), mengatasi perulangan dan *blank token* serta menghasilkan prediksi urutan karakter terbersih.

Strategi penelitian dirancang untuk memastikan stabilitas optimisasi dan kemampuan generalisasi yang baik. Model dioptimalkan menggunakan *Connectionist Temporal Classification* (CTC *Loss*) (Gao et al., 2021), yang dirancang untuk menghitung jarak antara dua urutan yang tidak selaras (*unaligned sequences*). Mekanisme ini sangat relevan pada tugas pengenalan tulisan tangan, dimana model tidak memiliki informasi *alignment* eksplisit antara fitur visual dengan karakter yang dihasilkan. Proses optimisasi dilakukan menggunakan *algoritma* Adam dengan *learning rate* awal sebesar 3×10^{-4}. Algoritma tersebut dipilih karena kemampuannya menyesuaikan *adaptive learning rate* pada setiap parameter sehingga mempercepat konvergensi pada data berskala besar. Selain itu, penelitian ini menggunakan *ReduceLROnPlateau scheduler* dengan *factor* 0.5 dan *patience* 2, yang secara otomatis menurunkan *learning rate* ketika validasi tidak menunjukkan perbaikan, sehingga mencegah terjadinya *plateaus* berkepanjangan. Selama pelatihan, strategi *early stopping* diterapkan untuk menghentikan proses ketika *validation loss* tidak mengalami peningkatan selama lima *epoch* berturut-turut, yang membantu menghindari *overfitting*.

Untuk memantau performa model, beberapa metrik dicatat pada setiap *epoch*, meliputi *training loss*, *validation loss*, dan akurasi berbasis *edit distance*. Performa dievaluasi menggunakan *Character Error Rate* (CER) sebagai metrik utama berbasis *edit distance*. *Character Error Rate* (CER) adalah metrik evaluasi yang digunakan untuk mengukur tingkat kesalahan pada sistem pengenalan teks, khususnya pada pengenalan karakter seperti *handwritten text recognition* dan *optical character recognition* (OCR). CER didefinisikan sebagai:

$$\text{CER} = \frac{S+D+I}{N}$$

Keterangan:
S (*Substitution*): jumlah karakter yang salah dikenali (karakter tertukar)
D (*Deletion*): jumlah karakter yang hilang
I (*Insertion*): jumlah karakter tambahan yang tidak seharusnya ada
N: jumlah total karakter pada teks referensi

Selain *Character Error Rate* (CER), kinerja model juga dievaluasi menggunakan metrik akurasi. Dalam penelitian ini, akurasi dihitung sebagai komplemen dari CER, yang merepresentasikan proporsi karakter yang berhasil dikenali dengan benar oleh sistem. Secara matematis, akurasi didefinisikan sebagai:

$$\textit{Accuracy} = 1 - \text{CER}$$

Metrik ini memberikan gambaran intuitif mengenai tingkat ketepatan model dalam mengenali karakter tulisan tangan secara keseluruhan. Penggunaan akurasi sebagai metrik pelengkap CER memudahkan interpretasi performa model, khususnya bagi pembaca non-teknis, sekaligus memperkuat analisis kuantitatif terhadap efektivitas sistem pengenalan teks tulisan tangan yang diusulkan.

HASIL DAN PEMBAHASAN

1. Implementasi Detail

Dataset tersebut disimpan dalam format NPZ (*NumPy Zipped File*), dimana setiap berkas NPZ berisi pasangan data citra tulisan tangan dan label teks yang bersesuaian. Pendekatan ini dipilih untuk meningkatkan efisiensi pemuatan data. Selama proses pelatihan, karena format NPZ memungkinkan penyimpanan *array* NumPy secara terkompresi dan akses data yang lebih cepat. Setiap berkas NPZ memuat dua komponen utama yaitu *images* berupa citra tulisan tangan baris teks dan labels berupa urutan karakter Hanzi yang sesuai dengan citra.

Pada tahap *preprocessing image*, setiap *input image* melakukan konversi ke *grayscale* untuk mengurangi kompleksitas kanal warna dan menyesuaikan dengan karakteristik data tulisan tangan. Selanjutnya, citra dinormalisasi ke *fixed-width* sebesar 32*px*, sedangkan *lebar* images disesuikan secara proporsional berdasarkan rasio aspek aslinya. Strategi ini diterapkan karena panjang teks pada setiap citra bervariasi, sehingga representasi *input* harus fleksibel terhadap perbedaan panjang sekuens. Dengan pendekatan ini, dimensi spasial citra dapat diproses secara konsisten oleh jaringan konvolusional, sekaligus menjaga proporsi visual karakter agar tidak terdistorsi.

Pada tahap pengumpulan label, seluruh label karakter dikumpulkan dari semua berkas NPZ, bukan hanya dari satu subset data, sehingga *vocabulary* yang dibangun mencerminkan keseluruhan karakter yang muncul dalam data pelatihan. Setiap karakter Hanzi dalam *vocabulary* dipetakan ke sebuah indeks numerik yang unik. Indeks 0 secara khusus dicadangkan sebagai *symbol blank* yang digunakan oleh algoritma *Connectionist Temporal Classification* (CTC) untuk merepresentasikan posisi tanpa karakter pada proses penyelarasan sekuens.

Seluruh berkas NPZ dibagi kedalam tiga subset: 80% data *train*, 10% data *validasi*, dan 10% data *test*. Ketiga subset ini diproses menggunakan model arsitektur yang dirancang khsusus untuk pengenalan teks tulisan tangan baris tanpa segmentasi karakter eksplisit (Y. Wang et al., 2021). Adapun alur kerja model yang dibangun adalah sebagai berikut:

1. *Convolutional Neural Network* (CNN) – citra tulisan tangan diproses oleh beberapa lapisan konvolusi dan *pooling* untuk mengekstraksi fitur visual tingkat rendah hingga tinggi.
2. Reduksi dimensi spasial – dimensi tinggi citra direduksi secara bertahap hingga menjadi satu baris fitur, sehingga citra dua dimensi diubah menjadi representasi sekuens satu dimensi sepanjang arah horizontal (lebar teks).
3. BiLSTM (*Bi-Long Short Term Memory*) – representasi sekuens kemudian diproses oleh LSTM dua arah untuk memodelkan ketergantungan konteks antar karakter, baik dari kiri ke kanan maupun sebaliknya.
4. Klasifikasi karakter – setiap langkah waktu menghasilkan prediksi distribusi kelas karakter, termasuk *symbol blank* yang digunakan oleh CTC.

5. Decoding dengan CTC – *output* model digunakan oleh CTC untuk menyelaraskan prediksi dan label, menghilangkan pengulangan dan menghasilkan urutan teks akhir.

Model ini dilatih menggunakan *optimizer* Adam (Saqib et al., 2022) dengan *learning rate* awal sebesar $3x10^{-4}$ (0.0003). Metode nilai tersebut dipilih karena Adam mampu menyesuaikan *learning rate* secara adaptif untuk setiap parameter dan tentunya mudah diterapkan karena membutuhkan memori yang relatif lebih rendah dan efisien dalam komputasi (Albayati et al., 2024). Nilai 3e-4 juga sangat umum digunakan dalam pelatihan model OCR berbasis CTC. Untuk meningkatkan performa pelatihan digunakan *ReduceLROnPlateau* yaitu mekanisme yang digunakan untuk memantau nilai *loss* pada data validasi dan menurunkan *learning rate* secara otomatis ketika performa tidak membaik. Pada penelitian ini, *learning rate* akan dikurangi menjadi setengahnya (*factor* = 0.5) jika *validation loss* tidak mengalami penurunan selama dua *epoch* berturut-turut. Metode *early stopping* juga digunakan untuk menghentikan pelatihan apabila performa tidak membaik selama lima *epoch* berturut-turut. Berdasarkan hasil pelatihan, model mencapai performa terbaik pada *epoch* ke-15 dan model pada *epoch* tersebut dipilih sebagai model akhir karena memiliki kemampuan generalisasi terbaik terhadap data yang tidak dilihat selama pelatihan.

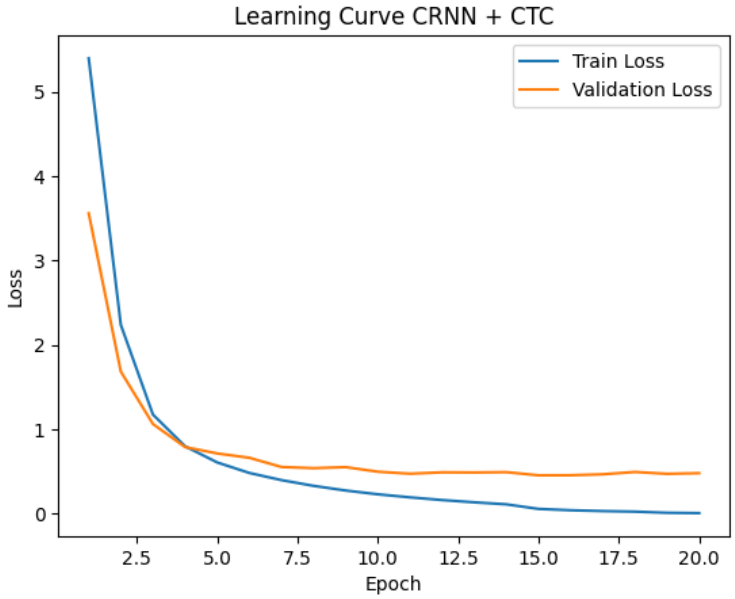
Selain evaluasi kuantitatif menggunakan nilai *training loss*, *validation loss*, serta metrik *Character Error Rate* (CER), penelitian ini juga melakukan evaluasi kualitatif terhadap hasil prediksi model. Evaluasi kualitatif dilakukan dengan membandingkan secara langsung antara *ground truth* dan hasil prediksi model pada data validasi. Pendekatan ini bertujuan untuk memberikan gambaran yang lebih komprehensif mengenai kemampuan model dalam mengenali karakter Hanzi, khususnya dalam konteks kesalahan yang tidak sepenuhnya dapat dijelaskan melalui metrik numerik.

Evaluasi kualitatif dilakukan dengan cara mengambil sejumlah sampel citra tulisan tangan dari *validation loader*, kemudian hasil keluaran model didekode menggunakan metode *Connectionist Temporal Classification* (CTC) untuk menghasilkan urutan karakter teks. Hasil *decoding* tersebut selanjutnya dibandingkan dengan label asli (*ground truth*) yang bersesuaian. Proses ini memungkinkan peneliti untuk mengamati secara langsung kesesuaian hasil prediksi model terhadap teks target pada level karakter dan urutan kata.

2. Hasil dan Pembahasan

Berdasarkan proses evaluasi pada dataset *test*, model yang diusulkan dalam penelitian ini menghasilkan *Character Error Rate* (CER) sebesar 16.85% dengan *accuracy*-nya sebesar 83.15%. Hasil ini diperoleh menggunakan metode CTC *greedy decoding* tanpa integrasi *language model*. Nilai CER menunjukkan bahwa sebagian besar karakter Hanzi berhasil dikenali dengan benar, meskipun masih terdapat kesalahan pada karakter yang memiliki bentuk visual kompleks atau kemiripan tinggi antar karakter.

Gambar 3 menunjukkan perkembangan *training loss* dan *validation loss* selama proses pelatihan. *Training loss* menurun secara stabil sedangkan *validation loss* mengalami fluktuasi yang merupakan karakteristik umum pada pelatihan berbasis CTC. Hal ini mungkin diakibatkan sensitivitas *alignment* dan variasi panjang sekuens pada data validasi. Model mencapai performa terbaik pada *epoch* ke-15 dan selanjutnya dihentikan menggunakan *early stopping* untuk mencegah *overfitting*.



Gambar 4. Kurva pembelajaran dari model CRNN-CTC

Hasil penelitian diatas tentu masih jauh dari hasil akurasi dari penelitian *offline* HCTR selama ini. Penelitian-penelitian lain banyak menggunakan seluruh subset CASIA-HWDB 2.0, 2.1, dan 2.2 dengan total lebih dari 52 ribu baris teks, serta menambahkan lebih dari 173 ribu data sintetis yang dibangun dari *database* karakter terisolasi HWDB 1.x. Sebaliknya, penelitian ini hanya mencakup subset HWDB 2.2 tanpa data sintetis tambahan, sehingga jumlah sampel dan variasi gaya tulisan yang tersedia bagi model jauh lebih terbatas.

Meskipun demikian hasil CER tersebut yang diperoleh dalam penelitian ini menunjukkan bahwa *pipeline* CRNN + CTC tetap mampu mempelajari pola dasar tulisan tangan Hanzi, bahkan dengan keterbatasan *dataset* dan tanpa bantuan *language model*.

Penelitian	Metode	Dataset	Akurasi / CER
Liu et al. (2020)	CNN + CTC	CASIA-HWDB	CER 6.81%
Zhuang et al. (2021)	CNN	CASIA-HWDB	Accuracy 90.91%
Wang et al. (2021)	Residual Attention FCN	CASIA-HWDB	Accuracy 90.91%
Penelitian ini	CRNN + BiLSTM + CTC	CASIA-HWDB 2.2	CER 16.85% / Accuracy 83.15%

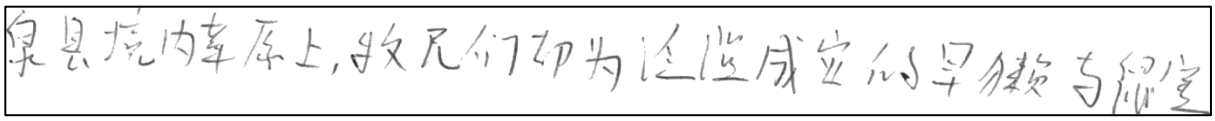
Tabel 1. Perbandingan hasil dengan penelitian sebelumnya

Berdasarkan Tabel 1, penelitian-penelitian sebelumnya umumnya menggunakan arsitektur yang lebih kompleks, data sintetis tambahan, maupun *language model* untuk meningkatkan performa pengenalan tulisan tangan Hanzi. Sebagai contoh, penelitian oleh (Liu et al., 2020). menggunakan *convolution-only architecture* dengan *synthetic data augmentation* dalam jumlah besar sehingga berhasil memperoleh CER sebesar 6.81% .

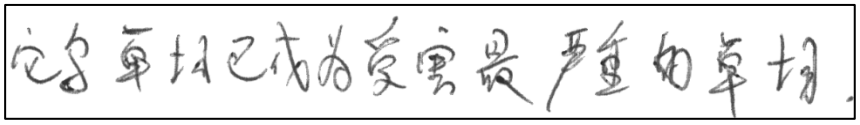
Sementara itu, penelitian ini menggunakan pendekatan CRNN berbasis CNN, BiLSTM, dan CTC tanpa *language model* maupun data sintetis tambahan. Meskipun nilai CER yang diperoleh masih lebih tinggi dibandingkan beberapa penelitian *state-of-the-art*, pendekatan yang diusulkan tetap mampu

menunjukkan kemampuan generalisasi yang baik pada pengenalan tulisan tangan Hanzi dengan kompleksitas implementasi yang lebih sederhana dan kebutuhan komputasi yang lebih ringan.

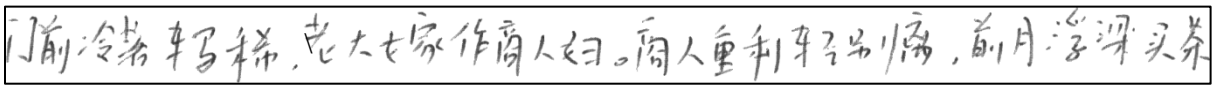
Selain itu, penggunaan BiLSTM pada penelitian ini memberikan kemampuan tambahan dalam mempelajari dependensi kontekstual antar karakter secara dua arah, yang menjadi salah satu keunggulan pendekatan CRNN dibanding pendekatan *convolution-only*.



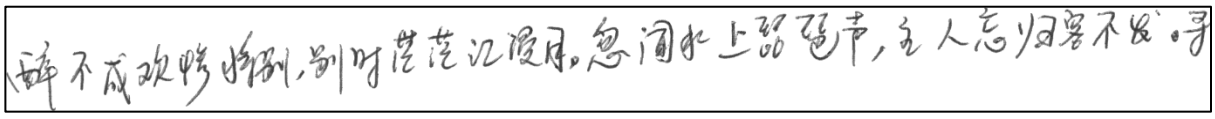
TRUE: 泉县境内草原上,牧民们却为泛滥成灾的旱獭与鼠害
PRED: 集县境内草原上,牧民们却为记滥成灾的旱獭放与能客。
Gambar 5. Contoh hasil prediksi dari model CRNN + CTC



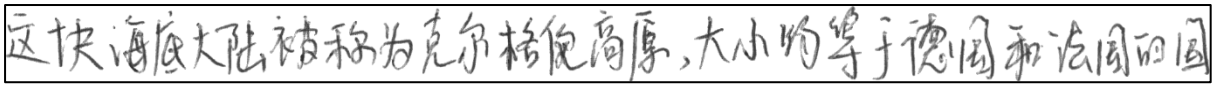
TRUE: 它乌草场已成为受害最严重的草场。
PRED: 它势草场已成为受害最严重的草场
Gambar 6. Contoh hasil prediksi dari model CRNN + CTC



TRUE: 门前冷落车马稀,老大嫁作商人妇。商人重利轻别离,前月浮梁买茶
PRED: 门前冷落车马稀,老大嫁作商人妇。商人重利轻别里,前月浮梁卖茶
Gambar 7. Contoh hasil prediksi dari model CRNN + CTC



TRUE: 醉不成欢惨将别,别时茫茫江浸月。忽闻水上琵琶声,主人忘归客不发。寻
PRED: 醉不成欢惨将别,别时茫茫江浸曰。忽闻水上琵琶生,主人忘归客不去。
Gambar 8. Contoh hasil prediksi dari model CRNN + CTC



TRUE: 这块海底大陆被称为克尔格伦高原,大小约等于德国和法国的国
PRED: 这块海底大路被称为克尔格伦高原,大小约等于德国和法国的国
Gambar 9. Contoh hasil prediksi dari model CRNN + CTC

Berdasarkan hasil pengamatan yang terlihat pada gambar 5 hingga 9, model mampu mengenali sebagian besar karakter dengan baik, termasuk pada teks dengan panjang sekuens yang cukup panjang. Hal ini menunjukkan bahwa kombinasi CNN dan BiLSTM berhasil mempelajari representasi spasial dan kontekstual tulisan tangan Hanzi secara efektif. Pada beberapa sampel, kesalahan prediksi hanya terjadi pada satu atau dua karakter, sementara struktur kalimat secara keseluruhan masih dapat dipertahankan. Sebagai contoh, pada Gambar 8 karakter “月” diprediksi sebagai “曰”, yang menunjukkan bahwa model mampu memahami konteks urutan karakter namun masih mengalami kesulitan membedakan detail *stroke*

kecil pada karakter tertentu. Namun tingginya tingkat kesesuaian antara hasil prediksi dan *ground truth* pada sebagian besar sampel mengindikasikan bahwa model mampu menangkap pola spasial dan sekuensial tulisan tangan secara efektif. Hal ini menegaskan bahwa arsitektur CRNN dengan pendekatan *end-to-end* berbasis CTC sesuai untuk permasalahan pengenalan tulisan tangan Hanzi, yang memiliki struktur karakter kompleks dan panjang urutan teks yang bervariasi.

Meskipun demikian, masih ditemukan kesalahan prediksi pada karakter tertentu, terutama pada karakter yang memiliki kemiripan bentuk visual atau ditulis dengan variasi gaya tulisan yang tinggi. Temuan ini sejalan dengan nilai *Character Error Rate* (CER) yang diperoleh pada evaluasi kuantitatif, dimana kesalahan umumnya terjadi pada satu atau lebih dari dua karakter dalam satu baris teks. Sebagian besar kesalahan prediksi terjadi pada karakter Hanzi yang memiliki kemiripan struktur visual maupun pola *stroke* yang hampir identik. Sebagai contoh, model beberapa kali mengalami kesalahan pada pasangan karakter seperti:

1. “乌” diprediksi sebagai “鸟”
2. “曰” diprediksi sebagai “月”
3. “里” diprediksi sebagai “理”
4. “县” diprediksi sebagai “集”

Kesalahan tersebut umumnya disebabkan oleh:

1. Kemiripan bentuk visual antar karakter Hanzi.
2. Variasi gaya tulisan tangan yang menyebabkan perubahan bentuk *stroke*.
3. Resolusi citra yang rendah sehingga detail karakter kompleks sulit dipertahankan.
4. Tidak digunakannya *language model* pada tahap *decoding* sehingga model hanya bergantung pada fitur visual.

Selain itu, karakter dengan jumlah stroke tinggi cenderung menghasilkan tingkat kesalahan lebih besar dibandingkan karakter sederhana. Hal ini menunjukkan bahwa kompleksitas visual karakter masih menjadi tantangan utama pada sistem HCTR berbasis CRNN. Untuk penelitian selanjutnya, performa model dapat ditingkatkan melalui penggunaan *beam search decoding*, integrasi *language model*, *data augmentation*, maupun arsitektur *attention-based network* untuk meningkatkan kemampuan diskriminatif model terhadap karakter yang mirip secara visual. Dengan demikian, hasil ini menunjukkan bahwa keterbatasan model lebih disebabkan oleh kompleksitas visual karakter dan variasi penulisan, bukan kegagalan arsitektur secara keseluruhan. Evaluasi kualitatif ini memberikan wawasan penting mengenai arah pengembangan selanjutnya, seperti peningkatan keragaman data pelatihan, penerapan teknik *data augmentation* atau penggunaan metode *decoding* yang lebih optimal untuk meningkatkan akurasi pengenalan karakter.

KESIMPULAN

Berdasarkan hasil perancangan, implementasi, dan pengujian sistem pengenalan teks tulisan tangan Hanzi yang telah dilakukan, dapat disimpulkan bahwa penelitian ini berhasil mengimplementasikan sistem *Offline Handwritten Chinese Text Recognition* menggunakan pendekatan *Convolutional Recurrent Neural Network* (CRNN) yang dikombinasikan dengan *Connectionist Temporal Classification* (CTC). Sistem dirancang secara *end-to-end*, mulai dari tahap prapemrosesan citra, ekstraksi fitur, pemodelan sekuens, hingga menghasilkan keluaran berupa teks Hanzi tanpa memerlukan proses segmentasi karakter secara eksplisit.

Hasil evaluasi pada dataset uji menunjukkan bahwa model yang diusulkan memperoleh *Character Error Rate* (CER) sebesar 16,85% dan akurasi sebesar 83,15% dengan menggunakan metode CTC *greedy decoding* tanpa penerapan *language model*. Nilai CER tersebut mengindikasikan bahwa sebagian besar karakter Hanzi telah berhasil dikenali dengan baik oleh sistem. Namun demikian, masih ditemukan kesalahan pengenalan terutama pada karakter yang memiliki struktur visual kompleks, jumlah goresan yang tinggi, serta kemiripan bentuk antar karakter, yang merupakan tantangan umum dalam pengenalan tulisan tangan Hanzi.

Selain itu, hasil penelitian ini menunjukkan bahwa kombinasi CRNN dan CTC mampu mempelajari keterkaitan spasial dan temporal dari citra teks tulisan tangan secara efektif, sehingga cocok diterapkan pada permasalahan pengenalan teks berurutan dengan panjang variatif. Penggunaan pendekatan CTC juga terbukti menyederhanakan proses pelatihan karena tidak memerlukan anotasi segmentasi karakter pada data latih, sehingga meningkatkan fleksibilitas dan efisiensi sistem.

Secara keseluruhan, sistem yang dikembangkan telah memenuhi tujuan penelitian dan dapat dijadikan sebagai *baseline* yang cukup kuat untuk pengembangan lebih lanjut pada sistem pengenalan teks tulisan tangan Hanzi. Hasil yang diperoleh menunjukkan potensi penerapan sistem ini pada berbagai aplikasi, seperti digitalisasi dokumen tulisan tangan, sistem arsip digital, serta aplikasi pembelajaran bahasa Mandarin.

SARAN

Pengembangan model dalam dunia *machine learning* tentu membutuhkan waktu yang banyak dan modal serta *resource* komputer yang mendukung untuk menjalankan proses pelatihan dan pengolahan data. Dikarenakan kondisi penulis yang cukup terbatas dalam segi *resources* dan waktu tentunya dalam penelitian ini menunjukkan adanya hasil evaluasi yang dapat ditingkatkan lagi oleh peneliti selanjutnya. Adapun berdasarkan hasil penelitian dan evaluasi dari model yang telah dikembangkan, terdapat beberapa saran yang dapat dijadikan acuan untuk pengembangan penelitian selanjutnya. Performa sistem dapat ditingkatkan dengan memperluas *dataset* pelatihan khususnya dengan menggabungkan seluruh subset CASIA-HWDB (HWDB 2.0, 2.1, 2.2) dan *Competition* 13 *line* sebagai data uji. Pengolahan data juga disarankan untuk menggunakan resolusi input citra yang lebih tinggi agar detail *stroke* karakter Hanzi dapat dipertahankan dengan lebih baik, mengingat kompleksitas struktur karakter Hanzi yang tinggi. Pengembangan selanjutnya juga dapat mengintegrasikan *language model* atau dapat juga menggunakan beam search decoding pada tahap inferensi untuk memperbaiki hasil pengenalan teks, terutama pada tingkat kata atau frasa. Selain itu, eksplorasi arsitektur jaringan yang lebih dalam dapat juga diterapkan lebih mendalam untuk meningkatkan kemampuan generalisasi model.

DAFTAR PUSTAKA

Albayati, A. Q., Altaie, S. A. J., & Al-obaydy, W. N. I. (2024). Performance analysis of optimization algorithms for convolutional neural network-based handwritten digit recognition. *International Journal of Artificial Intelligence*, *13*(1), 563–571. https://doi.org/10.11591/ijai.v13.i1.pp563-571

Alkendi, W., Gechter, F., & Heyberger, L. (2024). Advancements and challenges in handwritten text recognition : a comprehensive survey. *Artificial Intelligence Review*, *57*(2), 1–45. https://doi.org/10.1007/s10462-023-10547-9

Ayuni, D. P., Jasril, Irsyad, M., Yanto, F., & Sanjaya, S. (2023). Augmentasi data pada implementasi convolutional neural network arsitektur efficientNet-B3 untuk klasifikasi penyakit daun padi. *ZONAsi: Jurnal Sistem Informasi*, *5*(2), 239–249. https://doi.org/10.31849/zn.v5i2.13874

Chen, X., & Zhao, J. (2025). CCR-LWECNN : A lightweight CNN framework for Chinese calligraphy recognition and evaluation. *Informatica*, *49*(12), 361–376. https://doi.org/0.31449/inf.v49i12.8792

Gan, J., Wang, W., & Lu, K. (2020). In-air handwritten Chinese text recognition with temporal convolutional recurrent network. *Pattern Recognition*, *97*, 107025. https://doi.org/10.1016/j.patcog.2019.107025

Gao, L., Zhang, H., & Liu, C.-L. (2021). Handwritten text recognition with convolutional prototype network and most aligned frame based CTC training. In J. Lladós, D. Lopresti, & S. Uchida (Eds.), *Document Analysis and Recognition – ICDAR 2021* (pp. 203–218). Springer. https://doi.org/10.1007/978-3-030-86549-8_14

Geetha, R., Thilagam, T., & Padmavathy, T. (2021). Effective offline handwritten text recognition model based on a sequence-to-sequence approach with CNN–RNN networks. *Neural Computing and Applications*, *33*(17), 10923–10934. https://doi.org/10.1007/s00521-020-05556-5

Hu, M., Qu, X., Huang, J., & Wu, X. (2022). An end-to-end classifier based on CNN for in-air handwritten-

Chinese-character recognition. *Applied Sciences (Switzerland)*, *12*(14). https://doi.org/10.3390/app12146862

Hu, X., & Wu, F. (2024). Applications of machine learning in recognizing chinese calligrapher ' s handwriting styles. *Proceedings of the 5th International Conference on Computer Information and Big Data Applications (CIBDA 2024)*, 1–5. https://doi.org/10.1145/3671151.3671249

Kang, L., Riba, P., Villegas, M., Fornés, A., & Rusiñol, M. (2021). Candidate fusion: integrating language modelling into a sequence-to-sequence handwritten word recognition architecture. *Pattern Recognition*, *112*, 107790. https://doi.org/10.1016/j.patcog.2020.107790

Kass, D., & Vats, E. (2022). AttentionHTR: handwritten text recognition based on attention encoder-decoder networks. *Lecture Notes in Computer Science (Including Subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, *13237 LNCS*, 507–522. https://doi.org/10.1007/978-3-031-06555-2_34

Li, Z., Wu, Q., Xiao, Y., Jin, M., & Lu, H. (2020). Deep matching network for handwritten chinese character recognition. *Pattern Recognition*, *107*, 107471. https://doi.org/10.1016/j.patcog.2020.107471

Liu, B., Xu, X., & Zhang, Y. (2020). Offline handwritten chinese text recognition with convolutional neural networks. *Proceedings of the International Conference on Document Analysis and Recognition (ICDAR 2019)*, 1–6. http://arxiv.org/abs/2006.15619

Mamuriyah, N., & Jacky, J. (2021). Perancangan dan pembuatan alat untuk mendeteksi teks hangul dan inggris pada menu makanan menggunakan metode OCR (optical character recognition). *Telcomatics*, *6*(1), 1–10. https://doi.org/10.37253/telcomatics.v6i1.5054

Mamuriyah, N., & Sumantri, J. (2022). Penerapan metode convolution neural network (CNN) pada aplikasi automatic lip reading. *Journal of Informatics and Telecommunication Engineering*, *6*(1), 276–287. https://doi.org/10.31289/jite.v6i1.7523

Saqib, N., Haque, K. F., Yanambaka, V. P., & Abdelgawad, A. (2022). Convolutional-neural-network-based handwritten character recognition : an approach with massive multisource data. *Algorithms*, *15*(4), 129. https://doi.org/10.3390/a15040129

Shen, L., Chen, B., Wei, J., Xu, H., Tang, S.-K., & Mirri, S. (2023). The challenges of recognizing offline handwritten chinese : a technical review. *Applied Sciences*, *13*(6), 3500. https://doi.org/10.3390/app13063500

Vinh, T. Q., Duy, L. H., & Nhan, N. T. (2020). Vietnamese handwritten character recognition using convolutional neural network. *IAES International Journal of Artificial Intelligence*, *9*(2), 276–283. https://doi.org/10.11591/ijai.v9.i2.pp276-283

Wang, Y., Yang, Y., Ding, W., & Li, S. (2021). A residual-attention offline handwritten chinese text recognition based on fully convolutional neural networks. *IEEE Access*, *9*, 132301–132310. https://doi.org/10.1109/ACCESS.2021.3115606

Wang, Z., Du, J., & Wang, J. (2020). Writer-aware CNN for parsimonious HMM-based offline handwritten chinese text recognition. *Pattern Recognition*, *100*, 107102. https://doi.org/10.1016/j.patcog.2019.107102

Xie, C., Lai, S., Liao, Q., & Jin, L. (2020). High performance offline handwritten Chinese text recognition with a new data preprocessing and augmentation pipeline. In *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics): Vol. 12116 LNCS*. Springer International Publishing. https://doi.org/10.1007/978-3-030-57058-3_4

Yulianto, A., Andreas, W., & Sabariman, S. (2023). Perancangan prototype brankas menggunakan sistem pengenalan wajah dengan metode convolutional neural network (CNN). *Telcomatics*, *8*(1), 10. https://doi.org/10.37253/telcomatics.v8i1.7852

Zhuang, Y., Liu, Q., Qiu, C., Wang, C., Ya, F., Sabbir, A., & Yan, J. (2021). A handwritten chinese character recognition based on convolutional neural network and median filtering. *Journal of Physics: Conference Series*, *1820*(1), 012162. https://doi.org/10.1088/1742-6596/1820/1/012162